

INF623

2024/1



Inteligência Artificial

A17: Raciocínio Probabilístico IV

Plano de aula


- ▶ Modelos Ocultos de Markov
- ▶ Inferência
 - ▶ Filtragem
 - ▶ Previsão
 - ▶ Suavização
 - ▶ Explicação mais provável

Processos (ou cadeias) de Markov


Um **processo de Markov** é uma sequência de variáveis aleatórias onde a distribuição de cada variável depende apenas de um número fixo k de variáveis anteriores $X_{t-1}, X_{t-2}, \dots, X_{t-k}$:

Suposição de Markov

Para $k = 1$, dizemos que o modelo é de primeira ordem:



Para $k = 2$, dizemos que o modelo é de segunda ordem:



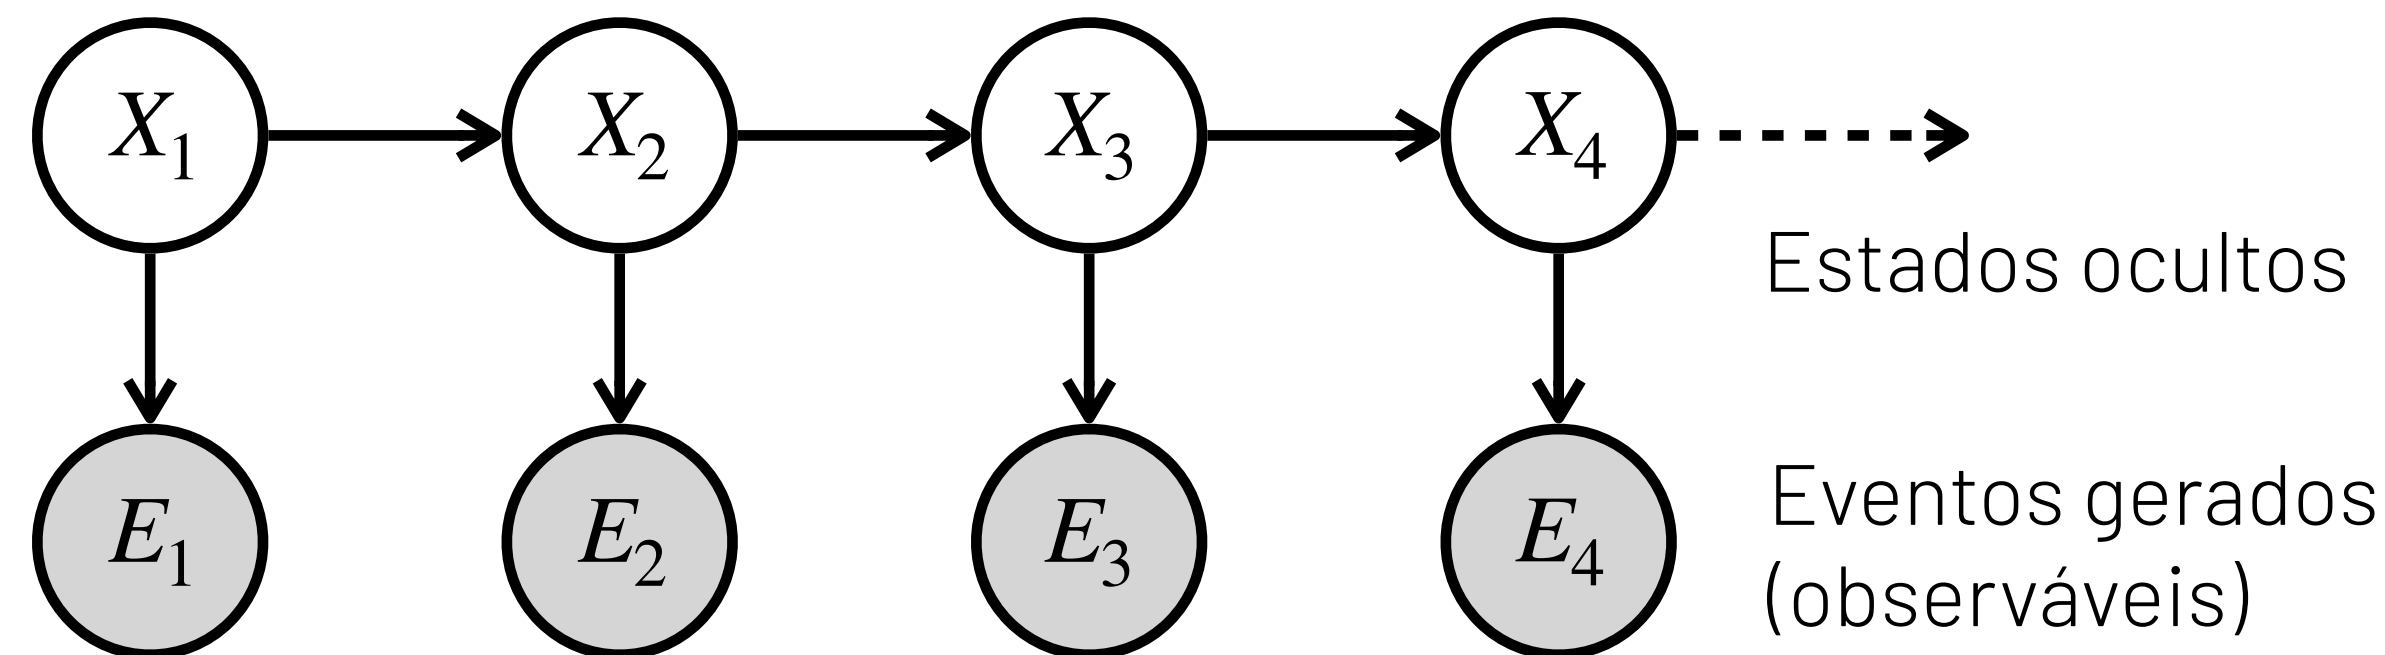
e assim por diante para $k = 3, 4, \dots$

Estados ocultos

- ▶ Processos de Markov são úteis em situações onde queremos prever estados futuros a partir de um estado inicial:
 - ▶ $P(X_2 = \text{☁️} \mid X_1 = \text{☀️})$
- ▶ No entanto, na prática, frequentemente não observamos os estados $X_1 = \text{☀️}$ diretamente, mas temos um "sensor" que nos dá informações sobre eles:
 - ▶ Reconhecimento de voz
 - ▶ Rastreamento de robôs
 - ▶ Atenção do usuário

Modelos ocultos de Markov (HMM)


Modelos ocultos de Markov são processos de Markov com estados ocultos X_t , onde cada estado produz uma observação E_t .



Um modelo oculto de Markov é definido por:

- ▶ Distribuição inicial – $P(X_1)$
- ▶ Modelo de transições – $P(X_t | X_{t-1})$
- ▶ Modelo de sensor – $P(E_t | X_t)$

Exemplos reais de HMMs



► Reconhecimento de voz

- Observações são sinais de áudio
- Estados são as palavras ditas em cada posição da frase

► Tradução de texto

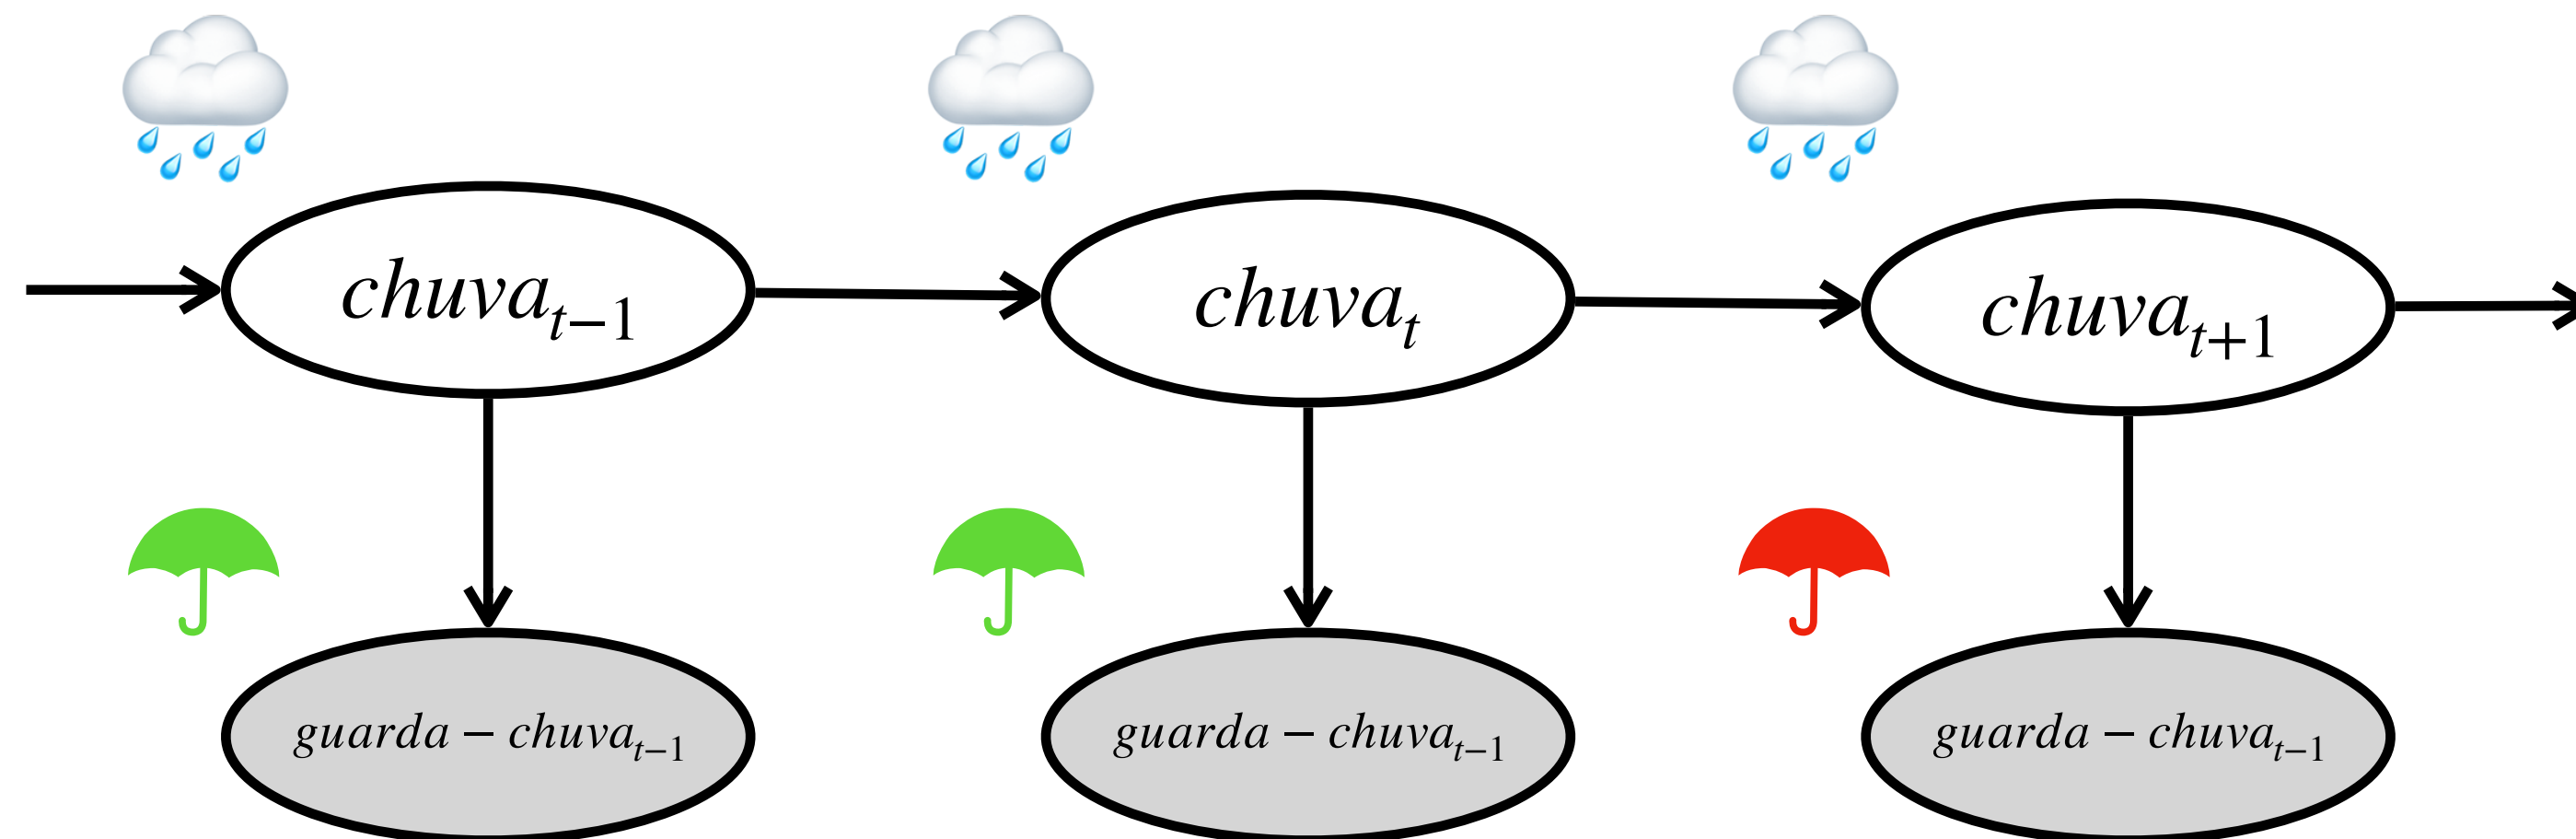
- Observações são palavras
- Estados são opções de tradução

► Rastreamento de robôs

- Observações são leituras de sensores de navegação
- Estados são as posições no mapa

Modelo de sensor

Além do estado inicial e do modelo de transição, um HMM possui um **modelo de sensor** $P(E_t | X_t)$ que especifica a distribuição de probabilidade do estado X_t produzir uma observação E_t .




X_{t-1}	X_t	$P(X_t X_{t-1})$
☀️	☀️	0,9
☀️	☁️	0,1
☁️	☀️	0,3
☁️	☁️	0,7

X_t	E_t	$P(E_t X_t)$
☀️	☂️	0,2
☀️	☂️	0,8
☁️	☂️	0,9
☁️	☂️	0,1

Suposição de sensores de Markov

A probabilidade do evento E_t depende apenas do estado X_t

Distribuição conjunta de HMMs



► Para 4 estados:

$$P(X_1, E_1, X_2, E_2, X_3, E_3, X_4, E_4) = P(X_1)P(E_1 | X_1)P(X_2 | X_1)P(E_2 | X_2)P(X_3 | X_2)P(E_3 | X_3)P(X_4 | X_3)P(E_4 | X_4)$$

► De uma maneira geral, para T estados:

$$P(X_1, E_1, X_2, E_2, \dots, X_T, E_T) = P(X_1)P(E_1 | X_1) \prod_{t=2}^T P(X_t | X_{t-1})P(E_t | X_t)$$

Inferência

Um HMM pode ser utilizado para diferentes tarefas de inferência:

► **Filtragem:** $P(X_t | e_1, \dots, e_t)$?

A probabilidade de chover hoje, dado todas as observações de guarda-chuva até o momento

► **Previsão:** $P(X_{t+k} | e_1, \dots, e_t)$?

A probabilidade de chover depois de amanhã, dado todas as observações de guarda-chuva até o momento

► **Suavização:** $P(X_k | e_1, \dots, e_t)$?

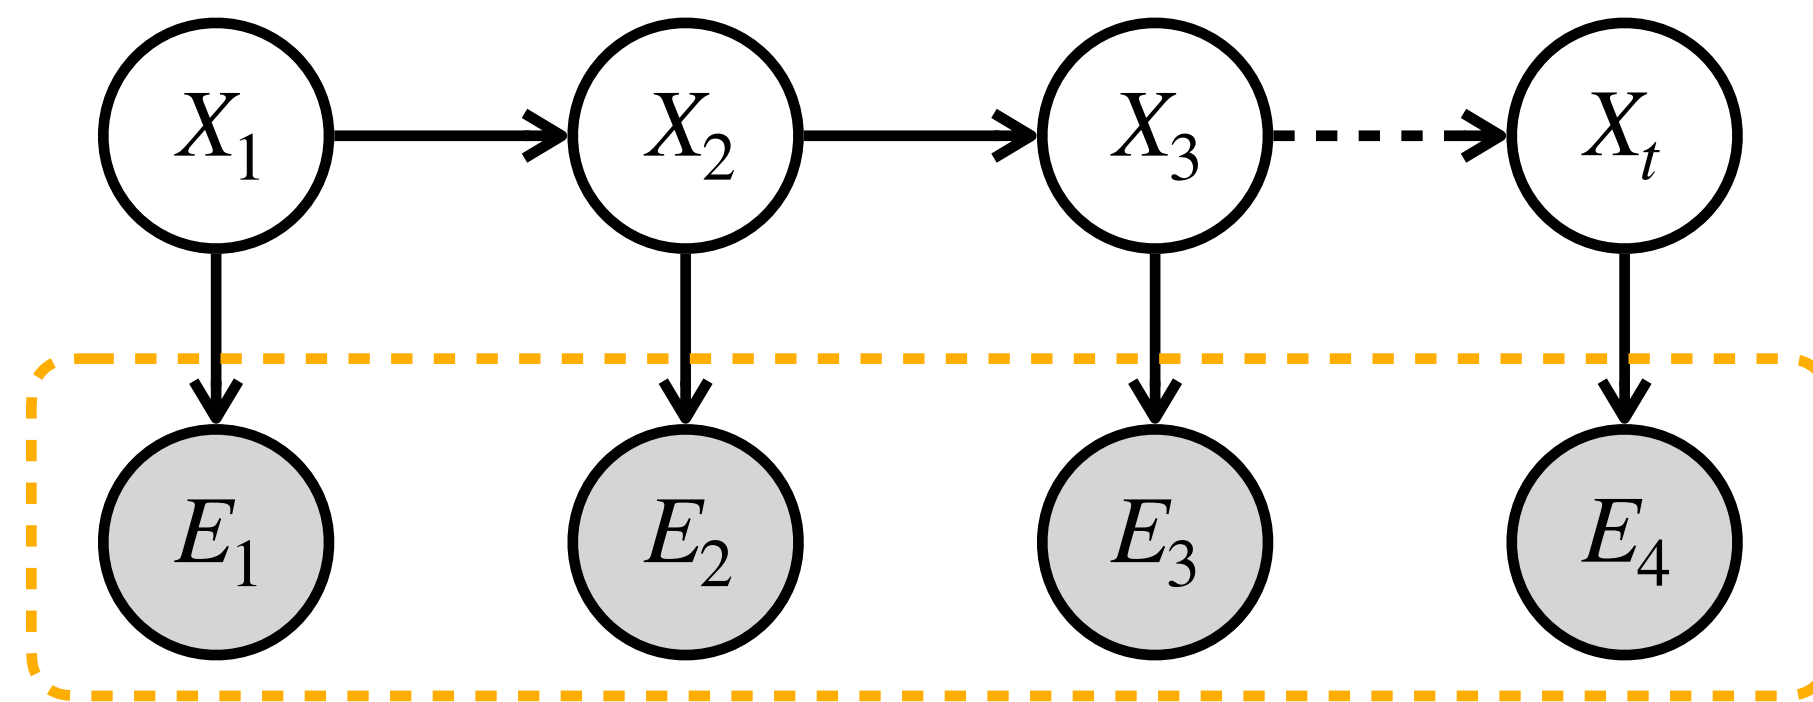
A probabilidade de que choveu na última quarta-feira, dado todas as observações de guarda-chuva até o momento

► **Explicação mais provável:** $\operatorname{argmax}_{x_{1:t}} P(x_{1:t} | e_1, \dots, e_t)$

A sequência de estados mais provável de ter gerado as observações obtidas.

Filtragem

Qual a probabilidade $B_t(X) = P(X_t | e_1, \dots, e_t)$, dado todas as observações até o momento?





Queremos: $P(X_t | e_1, \dots, e_t) = B_t(X)$

Observamos

- ▶ Começar $B_1(X) = P(X_1 | e_1)$, normalmente uniforme
- ▶ Atualizamos $B_t(X)$ a cada nova evidência e_t
- ▶ O **filtro de Kalman** foi inventado na década de 60 e implementado pela primeira vez como método de estimativa de trajetória para o programa Apollo.



Exemplo: Localização de robôs



Modelo de sensor: consegue ler em quais direções há uma parede, nunca mais do que 1 erro

Modelo de movimento: tem uma baixa probabilidade de falha.



Exemplo: Localização de robôs



Modelo de sensor: consegue ler em quais direções há uma parede, nunca mais do que 1 erro

Modelo de movimento: tem uma baixa probabilidade de falha.



Exemplo: Localização de robôs



Modelo de sensor: consegue ler em quais direções há uma parede, nunca mais do que 1 erro

Modelo de movimento: tem uma baixa probabilidade de falha.



Exemplo: Localização de robôs



Modelo de sensor: consegue ler em quais direções há uma parede, nunca mais do que 1 erro

Modelo de movimento: tem uma baixa probabilidade de falha.



Exemplo: Localização de robôs



Modelo de sensor: consegue ler em quais direções há uma parede, nunca mais do que 1 erro

Modelo de movimento: tem uma baixa probabilidade de falha.

Exemplo: Localização de robôs




Modelo de sensor: consegue ler em quais direções há uma parede, nunca mais do que 1 erro

Modelo de movimento: tem uma baixa probabilidade de falha.

Explicação mais provável

Qual é a sequência de estados mais provável de ter gerado as observações obtidas?



Próxima aula

A18: Processos de decisão de Markov I

Formalização matemática, exemplos, política, utilidade, descontos